

Arbeidskrav 3 - regresjonsanalyse

Merete Sustad Lien

2026-10-05

HSV (Helse og sosialvitenskapelig fakultet)

Arbeidskrav 3 - Regresjonsanalyse

Høst 2026

Studieprogram: Treningsfysiologi

Emnekode: IDR4000

Oppgave 1: Beskrive sammenhenger


Oppgave 1.1: Sammenheng mellom to kontinuerlige variabler

Når man undersøker sammenhengen mellom to kontinuerlige variabler i en regresjonsmodell, benyttes det oftest en enkel lineær regresjonsanalyse. Målet med analysen er å finne og tilpasse en rett linje til et sett med datapunkter, slik at residualene – det vil si avviket mellom det observerte og det forventede – blir minst mulig. Enkel lineær regresjon bruker én uavhengig variabel (x) til å forutsi eller forklare en avhengig variabel (y). Forholdet mellom variablene uttrykkes gjennom en matematisk formel, hvor man antar at y -verdiene er normalfordelt rundt et gjennomsnitt (μ) med et gitt standardavvik (σ):

$$y \sim \text{Normal}(\mu, \sigma)$$
$$\mu = \beta_0 + \beta_1 x$$

For å visualisere og eksemplifisere dette kan man ta utgangspunkt i datasettet *hypertrophy*, og se på sammenhengen mellom utøvernes prosentandel av type II-muskelfibre ved oppstart (PERCENT_TYPE_II_T1) og tykkelsen på vastus lateralis etter 6 uker med trening (VL_T3). En enkel regresjonsanalyse ga følgende estimerte regresjonsformel, hvor μ representerer forventet gjennomsnittlig muskeltykkelse:

$$\mu = 2.81 + 0.0058 \cdot \text{prosentandel type II-fibre}$$



Figur 1: Blå linje viser regresjonslinjen i modellen

Skjæringspunktet ($\beta_0 = 2.81$) angir gjennomsnittlig målt muskeltykkelse i tilfellet $x = 0$, det vil si 0% type II-muskelfibre. Siden det biologisk sett ikke er mulig å ha 0% type II-muskelfibre, blir dette bare en matematisk konstant i diagrammet og ikke en reell fysiologisk verdi.

Regresjonsestimatet (β_1), som representerer regresjonslinjens stigningstall, er her 0.0058. I eksempelet betyr det at for hvert prosentpoeng høyere andel av type II-muskelfibre en utøver har ved oppstart, er det forventet en gjennomsnittlig økning på 0.0058 cm i muskeltykkelse etter intervensjonen. Regresjonsestimatet er imidlertid ikke statistisk signifikant, vist ved høy p -verdi på 0.323.

I eksempelet er Pearsons korrelasjonskoeffisient beregnet til $r = 0.19$, som beskriver styrken og retningen av den lineære sammenhengen. Siden verdien er nær 0 og har positivt fortegn, er tolkningen av det at det er en svak, positiv korrelasjon mellom variablene, men dette er svært usikkert og kan tilskrives tilfeldighet. Dersom man ønsker å se den faktiske, ustandardiserte effekten av muskelfibertype på endring i muskeltykkelse, er det regresjonsestimatet som må tolkes.

Både korrelasjonskoeffisienten og regresjonsestimatet beskriver den underliggende lineære sammenhengen i dataene, og de vil alltid dele retning. Dette vises ved likt fortegn. Der korrelasjonskoeffisienten er et standardisert mål mellom -1 og 1 som er uavhengig av enheter, vil regresjonsestimatet vise effekt målt i dataenes egne enheter, her cm per prosentpoeng. Med andre ord er stigningstallet til regresjonslinjen det samme som korrelasjonskoeffisienten justert for forholdene mellom standardavvikene mellom de to variablene.

Oppgave 1.2: Sammenheng mellom kontinuerlig og kategorisk variabel

Statistiske programvarer klarer ikke å regne direkte med merkelapper eller tekst, og er derfor avhengige av å kode om fra tekst til tall. Når man inkluderer en kategorisk variabel i en regresjonsmodell, benytter man såkalte dummyvariabler. Dette innebærer at programmet tildeler den ene gruppen verdien 0 (referansegruppen), mens den andre tildeles verdien 1 (sammenligningsgruppen). Modellen vil følge samme matematiske formel som i oppgave 1.1:


$$y \sim \text{Normal}(\mu, \sigma)$$

$$\mu = \beta_0 + \beta_1 x$$

Her representerer μ gjennomsnittlig muskeltykkelse i vastus lateralis, β_0 er modellens skjæringspunkt, β_1 er regresjonsestimatet – som her indikerer forskjellen mellom gruppene – og x er dummyvariabelen. Siden referansegruppens dummyvariabel er kodet som $x = 0$, vil skjæringspunktet i modellen representere referansegruppens gjennomsnittlige muskeltykkelse etter 6 uker trening.

Et praktisk eksempel på dette er sammenhengen mellom den kontinuerlige avhengige variabelen «muskeltykkelse på vastus lateralis etter 6 uker» (VL_T3) og den kategoriske uavhengige variabelen «kosttilskudd» (GROUP) i datasettet *hypertrophy*, hvor dataene er filtrert til å kun omhandle karbohydratgruppen (MALTO) og proteingruppen (WP). Analysen i R ga følgende estimerte regresjonsformel:

$$\mu = 3.2310 - 0.1250 \cdot \text{dummyvariabel}$$



Figur 2: Rød linje viser gjennomsnittlig forskjell mellom gruppene

Dummyvariabelen for referansegruppen (MALTO) er satt til 0. Det betyr at skjæringspunktet ($\beta_0 = 3.2310$) uttrykker den gjennomsnittlige muskeltykkelsen for gruppen som inntok karbohydrater. Det negative regresjonsestimatet ($\beta_1 = -0.1250$) representerer forskjellen mellom gruppene og betyr at utøverne som inntok proteinpulver (WP), i gjennomsnitt hadde 0.125 cm mindre muskeltykkelse enn utøverne i referansegruppen. Heller ikke her er regresjonsestimatet statistisk signifikant, vist ved høy p -verdi på 0.509, så det er usikker hvor reell effekt det er snakk om.

Oppgave 1.3: Generalisert lineær modell

Vanlig lineær regresjon tar utgangspunkt i at dataene følger en normalfordeling. I tilfeller hvor den avhengige variabelen er binær – det vil si at den kun tar verdien 0 eller 1 – jobber man med en binomialfordeling med kun to mulige utfall. I analyse av slike data tar man i bruk en generalisert lineær modell (GLM), som åpner muligheten for å gjøre analyser på data som ikke er normalfordelt.


Datasettet *hypertrophy* er tatt i bruk for å visualisere dette, hvor man kan stille følgende spørsmål: «Kan vi bruke type II muskelfiber hos utøverne ved oppstart for å forutsi om utøverne får god (HIGH) eller dårlig (LOW) respons med tanke på muskelvekst etter treningsintervensjon?».

For å kunne forutsi om noe skjer eller ikke skjer, bruker man logistisk regresjon. Når man gjør en slik analyse i R, får man ut et rå-estimat som er oppgitt som den naturlige logaritmen til oddsen (log-odds). Dessverre er dette et tall som gir lite mening når man forsøker å tolke det

biologisk eller fysiologisk. Man utfører derfor en eksponensiering av rå-estimatet for å få en odds-ratio ($OR = e^\beta$). I eksempelet blir dette $e^{0.04387} = 1.045$. Odds-ratio er et forholdstall som beskriver hvordan oddsen endrer seg basert på endringer av den uavhengige variabelen. En odds-ratio på 1.045 forteller oss at for hvert prosentpoeng økning i andel type II-muskelfibre hos utøver ved start, øker oddsen for å bli en «high-responder» med 4.5%. Resultatet er ikke statistisk signifikant, vist ved p -verdi = 0.200, men resultatene indikerer en positiv tendens i dette utvalget.

Siden den avhengige variabelen er binær (0 eller 1), kan vi ikke bruke en tradisjonell lineær regresjonslinje, da denne ville forutsagt verdier under 0 og over 1. Modellens link-funksjon (logit) gjør om den rette linjen til en S-kurve, slik at modellen alltid holder seg innenfor 0% og 100%. Dette er viktig for at modellen ikke skal produsere tall som ikke gir biologisk eller statistisk mening i form av umulige sannsynligheter.

Figuren viser at gruppen med «high-responders» generelt har en høyere prosentandel type II-muskelfibre ved oppstart.



Figur 3: Boksplo som sammenligner prosentandel av type II-muskelfibre ved oppstart (T1) mellom deltakere med lav respons (0) og høy respons (1) i muskelvekst

Oppgave 2: Predikere mulige observasjoner

Oppgave 2.1: Prediksjonsmodell med fullt datasett

Datasettet ble først filtrert til et bredt format der øvelsene «legpress» og «legext» ble tildelt hver sin kolonne, mens øvrige øvelser ble ekskludert fra datamaterialet. Prediksjonsmodellen tilsvarende struktur som tidligere:


$$y \sim \text{Normal}(\mu, \sigma)$$

$$\mu = \beta_0 + \beta_1 x$$

Basert på den statistiske analysen av det filtrerte utvalget, ble følgende estimerte regresjonsformel utarbeidet, hvor μ representerer gjennomsnittlig verdi av legext:

$$\mu = 19.20 + 0.25 \cdot \text{legpress}$$

Skjæringspunktet ($\beta_0 = 19.20$) angir den teoretiske startverdien i «legext» dersom en utøver tar 0 kg i «legpress». Regresjonsestimatet ($\beta_1 = 0.25$) representerer prediksjonsmodellens stigningstall. Det forteller oss at for hver kilo en utøver øker sin maksimale styrke i «legpress», forventes det en gjennomsnittlig økning på 0.25 kg i «legext» for dette utvalget.



Figur 4: Modellen viser en sterk og signifikant sammenheng mellom øvelsene. Dette vises med en p-verdi < 0.001 . Mørkere prikker i figuren visualiserer flere data i samme område

Oppgave 2.2: Prediksjonsmodell med spesifikke betingelser

Prediksjonsmodellen i oppgave 2.1 ble videreutviklet for å undersøke sammenhengen mellom «legext» og «legpress» under spesifikke betingelser. Datamaterialet fra «strengthvolume» ble derfor filtrert til å kun omfatte målinger fra «post» - det vil si testtidspunktet etter intervensjonen (time == «post»)– og for gruppen som trente med lavt treningsvolum (sets == «single»). Formelen under skal derfor kunne brukes for å predikere styrke i «legext» basert på «legpress» hos utøvere som har gjennomført en treningsperiode med kun ett sett per øvelse. Modellen fortsetter å følge den lineære regresjonsstrukturen:


$$y \sim \text{Normal}(\mu, \sigma)$$

$$\mu = \beta_0 + \beta_1 x$$

Basert på den statistiske analysen av dette spesifikke utvalget, ble følgende estimerte regresjonsformel formet:

$$\mu = 28.94 + 0.23 \cdot \text{legpress}$$

Skjæringspunktet ($\beta_0 = 28.94$) angir den teoretiske startverdien i «legext» ved post-testen for gruppen som trente ett sett, dersom styrken i «legpress» hadde vært 0 kg. Regresjonsestimatet ($\beta_1 = 0.23$) representerer modellens stigningstall. Det forteller at for hver kilo utøverne i denne gruppen øker i «legpress» ved endt intervensjon, forventes en gjennomsnittlig økning på 0.23 kg i «legext». Modellen viser en sterk og statistisk signifikant sammenheng mellom øvelsene, bekreftet av en lav p -verdi ($p < 0.001$).



Figur 5: Utvalget er filtrert til å omhandle deltakerne i single-sett gruppen ved post-test

Oppgave 2.3: Prediksjonsmodell med utgangspunkt i kjønn

Modellen utvides fra en enkel til en multippel lineær regresjonsmodell, dette er for å undersøke hvordan kjønn (sex) påvirker prediksjonen av styrke i «legext» forklart av «legpress». Funksjonen `lm()` brukes fortsatt og R setter automatisk kvinner til referansegruppe (0) og menn til sammenligningsgruppe (1). Kjønn kan inkluderes i modellen på to forskjellige måter, for å se effekten i gjennomsnitt eller innad i kjønnene.

Dersom vi antar at økning i styrke er lik på tvers av kjønn - det vil at begge kjønn øker like mye i «legext» per kilo «legpress» - kan følgende formel brukes:


$$\mu = \beta_0 + \beta_1 \cdot \text{legpress} + \beta_2 \cdot \text{sex}$$

Kvinnerenes regresjonslinje ($\text{sex} = 0$) følger formelen: $\mu = \beta_0 + \beta_1 \cdot \text{legpress}$. Skjæringspunktet β_0 viser hvor kvinnerenes linje starter på y – akse.

Mennenes regresjonslinje ($\text{sex} = 1$) følger formelen: $\mu = (\beta_0 + \beta_2) + \beta_1 \cdot \text{legpress}$. Estimert (β_2) viser den faste, gjennomsnittlige avstanden mellom de to linjene.

Regresjonsmodellen ga følgende estimerte formel:

$$\mu = 37.54 + 0.15 \cdot \text{legpress} + 21.86 \cdot \text{sex}$$



Figur 6: Spredningsdiagram med parallelle regresjonslinjer (gjennomsnitt)

Dersom det tas høyde for at kvinner og menn har ulike stigningstall, det vil si at treningseffekten er forskjellig mellom kjønnene, legges det til et interaksjonsledd i formelen.


$$\mu = \beta_0 + \beta_1 \cdot \text{legpress} + \beta_2 \cdot \text{sex} + \beta_3 \cdot (\text{legpress} \cdot \text{sex})$$

Kvinnerenes regresjonslinje ($\text{sex} = 0$) følger fremdeles formelen $\mu = \beta_0 + \beta_1 \cdot \text{legpress}$. Effekten av «legpress» hos kvinner er det rene estimatet β_1 (stigningstall).

Siden mennene er satt som sammenligningsgruppe ($\text{sex} = 1$), blir alle leddene i formelen aktivert. Med andre ord vil effekten av «legpress» hos menn bli summen av kvinnerenes effekt og interaksjonsleddet.

Regresjonsmodellen ga følgende estimerte formel:

$$\mu = 37.31 + 0.15 \cdot \text{legpress} + 22.30 \cdot \text{sex} - 0.002 \cdot (\text{legpress} \cdot \text{sex})$$



Figur 7: Spredningsdiagram med interaksjonseffekt for kjønn

Call:

```
lm(formula = legext ~ legpress * sex, data = strengthvolume_filt)
```

Residuals:

Min	1Q	Median	3Q	Max
-24.334	-9.179	-2.448	5.850	28.935

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	37.306077	14.830915	2.515	0.0179 *
legpress	0.150893	0.064332	2.346	0.0263 *
sexmale	22.299020	21.603681	1.032	0.3108
legpress:sexmale	-0.001796	0.085438	-0.021	0.9834

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.78 on 28 degrees of freedom

(7 observations deleted due to missingness)

Multiple R-squared: 0.6567, Adjusted R-squared: 0.6199

F-statistic: 17.86 on 3 and 28 DF, p-value: 1.127e-06

Oppgave 2.4: Prediksjonsintervall

Oppgaven tar utgangspunkt i modellen fra oppgave 2.3:

$$\mu = \beta_0 + \beta_1 \cdot \text{legpress} + \beta_2 \cdot \text{sex} + \beta_3 \cdot (\text{legpress} \cdot \text{sex})$$

La oss si at en mann tar 150 kg i “legpress”. For denne verdien gir modellen et punktestimat, også kalt et gjennomsnittsestimat, og i eksempelet gir modellen en estimert «legext»-verdi på 81.97 kg. Siden enkeltpersoner varierer naturlig, kan det være nyttig og naturlig å finne et område som man forventer at nye, individuelle observasjoner havner innenfor – et såkalt prediksjonsintervall. Man kan da med 95% sikkerhet si at vi forventer at en ny, enkeltstående person havner innenfor intervallet. I eksempelet med den gitte verdien på legpress, vil man få en legext-verdi som ligger i området mellom 51.43 kg og 112.51 kg. Dette intervallet er relativt bredt fordi det tar høyde for både usikkerheten i selve regresjonsmodellen og den naturlige variasjonen (residualene) som eksisterer mellom enkeltpersoner innad i populasjonen.

Oppgave 3: Trekke slutninger

Oppgave 3.1: Endring


For å løse oppgaven har jeg valgt å gjøre en lineær regresjon med “sett” som en uavhengig kategorisk variabel og endringen i styrke som en avhengig kontinuerlig variabel. Dette gjør det mulig å se på hvilken måte antall sett påvirker endringen i muskelstyrke før og etter treningsintervensjonen, og det vil produsere et direkte estimat på forskjellen i gjennomsnittlig styrkeøkning mellom treningsvolumene.

Datasettet ble filtrert på øvelsen «legext» og tidspunktene «pre» og «post», og videre ble datasettet omgjort til et bredt format hvor de to tidspunktene ble tildelt egne kolonner med sine respektive verdier for hver deltaker. Det ble på den måten mulig å beregne den faktiske endringen mellom tidspunktene, som utgjorde den nye kontinuerlige variabelen.

Resultatene ga følgende estimerte regresjonsmodell:

$$\mu = 32.21 - 3.65 \cdot \text{sett}$$

Dataene er presentert som et boksplot. Hvit diamant viser gjennomsnittlig endring i styrke for de respektive gruppene, og visuelt kan man se at forskjellen i høyde viser forskjellen mellom gruppene. Konstanten ($\beta_0 = 32.21$) viser at gruppen som trente flere sett (multiple = 0) hadde en gjennomsnittlig økning på 32.21 kg. Regresjonsestimatet ($\beta_1 = -3.65$) viser at gruppen som trente ett sett (single = 1) hadde en mindre gjennomsnittlig økning.



Figur 8: Hvit diamant viser gjennomsnittlig endring i hver gruppe

Oppgave 3.2: Generalisering til populasjon

Det aktuelle datasettet og regresjonsmodellen er basert på et begrenset utvalg av deltakere. Når man skal bruke regresjonsmodellen for å se på populasjonen ellers, så er det i hovedsak to statistiske mål man kan bruke. Dette er p -verdien (statistisk signifikant) og standardfeil (konfidensintervall).

P -verdien på 0.268 er betydelig større enn signifikansnivået som er satt til 0.05, som indikerer at forskjellen mellom treningsvolumene ikke er statistisk signifikant. Det betyr at resultatene ikke kan generaliseres, og forskjellen i nettopp dette utvalget kan skyldes rene tilfeldigheter og støy. Den aktuelle regresjonsmodellen kan derfor ikke brukes for å måle effekten på populasjonen ellers.

Standardfeilen måler usikkerheten i estimatene. Modellen har en høy standardfeil på 3.27, som man ser er nesten like stor som regresjonsestimatet. Dette gir en høy usikkerhet rundt tallene. Høy standardfeil gir lav t -verdi og høy p -verdi. Den høye standardfeilen viser at det er høy grad av tilfeldig variasjon, så det kan ikke konkluderes sikkert om effekten er reell i populasjonen.

Vedlegg

Github-lenke: